# 论文复现报告：分子文本表示对 LLM 的影响

模型 deepseek-flash | smoke 270 请求 | partial reproduction（论文模型未跑）

## 一、复现目标与范围

论文测量"同一个分子写成不同文本表示，LLM 回答是否改变"。本次复现 9 种表示 × 8 类任务，实际执行 smoke profile（270 条），paper profile（29139 条）与论文 15 个模型本次均未执行，属 partial reproduction。

## 二、来源与环境

仓库 https://github.com/arunraja-hub/molrepbench，commit 21d36941cddf0dc1ffb5f3590296592dc68e4ac8，vendor 32/32 校验未改。

Python 3.12.15；RDKit 2025.9.6；OpenBabel MISSING；单元测试 11/11。

## 三、九种表示与八类任务

| 表示 | 编码什么 | 立体/电荷 | 为何用它 |
|---|---|---|---|
| canonical_smiles | 规范化 SMILES | 无 | 基准对照 |
| isomeric_smiles | 含 @/@@ 的 SMILES | 保留立体 | 检验立体信息 |
| randomized_smiles | 随机顺序 SMILES | 无 | 同一分子不同写法 |
| deepsmiles | 紧凑 SMILES 变体 | 无 | 可能丢语义 |
| iupac | 系统命名 | 多丢失状态 | 语义线索但会标准化 |
| selfies | 语法合法即分子 | 语法层面 | 区分幻觉与非法 |
| moljson | 全原子键 JSON | 可含 | 信息全但长 |
| cml | XML 化学标记语言 | 可含 | 显式图结构最长 |
| inchi | 规范化哈希 | 含立体层 | 难反推 |

| 表示 | 平均字符数（实测） |
|---|---|
| canonical SMILES（规范 SMILES） | 70 |
| randomized SMILES（随机写法） | 73 |
| DeepSMILES | 74 |
| isomeric SMILES（含立体） | 100 |
| IUPAC 名称 | 158 |
| InChI | 228 |
| SELFIES | 341 |
| MolJSON | 2888 |
| CML（化学标记语言） | 4363 |

| 任务 | 测什么 | 指标 |
|---|---|---|
| B1 | 数原子 | accuracy |
| B2 | 认官能团 | macro-F1 |
| B3 | logP/TPSA/HBD/HBA | Spearman / accuracy |
| B4 | 四选一 | accuracy |

| 任务 | 测什么 | 指标 |
| --- | --- | --- |
| B5 | 同一性判断 | accuracy |
| B6 | 逆向生成 | validity + exact + Tanimoto |
| B9 | 互变异构体 | accuracy |
| B10 | 质子化状态 | accuracy |

## 四、真实链路示例（节选 B1 与 B6）

B1:439741:C:canonical_smiles（canonical SMILES（规范 SMILES），finish_reason=stop）

prompt：How many C atoms are in the following molecule? / Molecule: Nc1ncnc2c1ncn2C1OC(COP(=O)(O)OP(=O)(O)OCC(O)C(=O)O)C(O)C1O / / Please reason step by step, and put your final answer within \boxed{}. / / Example format: After reasoning, conclude with: The answer is \boxed{4

参考答案：13｜模型解析答案：13｜判分：正确

B6:5354212:generation:canonical_smiles（canonical SMILES（规范 SMILES），finish_reason=stop）

prompt：Given a description of a molecule, generate the corresponding Canonical SMILES string. / / IMPORTANT: Don't restate the full description - get straight to generating the molecule. Keep any reasoning brief and concise. Output tokens are limited, so provide your fi

参考答案：COC(=O)/C=C1/CC[C@H]2[C@@H]3CCC4=CC(=O)CC[C@]4(C)[C@H]3C(=O)C[C@]12C｜模型解析答案：COC(=O)C=C1CC[C@H]2[C@@H]3CCC4=CC(=O)CC[C@]4(C)[C@H]3C(=O)C[C@]12C｜判分：正确

## 五、成绩与覆盖

API 成功 270/270，解析答案 269，result_kind=real_model_inference。

| 任务 | 题数 | 已判分 | 正确 | 正确率 |
| --- | --- | --- | --- | --- |
| B1 | 18 | 18 | 14 | 0.78 |
| B2 | 90 | 90 | 78 | 0.87 |
| B3 | 72 | 72 | 9 | 0.12 |
| B4 | 18 | 18 | 18 | 1.00 |
| B5 | 18 | 18 | 13 | 0.72 |
| B6 | 18 | 18 | 3 | 0.17 |
| B9 | 18 | 18 | 10 | 0.56 |
| B10 | 18 | 18 | 16 | 0.89 |

bootstrap comparisons = 0：实现要求每组至少 3 个配对分子，smoke 每任务仅 2 个分子，拒绝给出无意义的置信区间；未放宽阈值。

## 六、真实失败案例

1. 输出被截断｜B3:439741:tpsa:randomized_smiles｜finish_reason=length，消耗 8299 tokens（上限 8192）｜判定：未解析答案，记为未评估，不删除

2. 输出被截断｜B6:5354212:generation:selfies｜finish_reason=length，消耗 8388 tokens（上限 8192）｜判定：未解析答案，记为未评估，不删除

3. 输出被截断｜B6:53239731:generation:selfies｜finish_reason=length，消耗 8425 tokens（上限 8192）｜判定：未解析答案，记为未评估，不删除

4. 答案错误｜B1:439741:C:selfies｜模型给出了可解析的答案，但与标准答案不一致｜判定：记为错误（计入分母）

5. 答案错误｜B2:439741:ester:deepsmiles｜模型给出了可解析的答案，但与标准答案不一致｜判定：记为错误（计入分母）

## 七、数据本身的问题

IUPAC 审核：4551 个成员中仅 2697 个名称与成员 SMILES 立体身份一致，41 个仅连接性一致，1567 个不一致，287 个无法解析。

B9：The 4 disputed B9 labels are robust: they disagree with current RDKit default AND 10000-tautomer enumeration. The disagreement is therefore not an artifact of enumeration limits; cause requires author clarification (version/standardization difference). Public labels kept unchanged.

## 八、完成与未完成

已完成：环境、vendor 校验、单元测试、smoke/paper 计划、离线审计、OPSIN 审核、verified 路线、270 条真实推理、评分与失败案例分析。

未完成：paper profile 29139 请求、论文 15 个模型、thinking on 条件、FCD、LLM 裁判图、§6 tokenizer 与机制分析。

替代实现：Windows CML 走 obabel CLI（与作者 cml_to_smiles 同款方式）。