分子文本表示论文理解与复现指南

Rethinking Molecular Text Representations for LLMs

供教授汇报准备与 CodeBuddy 本地执行使用

本项目已找到并取得作者公开代码与数据，完成便携 Python 实现、离线数据审计和软件检查。目前没有执行真实 LLM 推理，因此本文件是论文理解与运行指南，不能作为“已成功重现论文成绩”的结果报告。

这次要复现什么

论文的问题是：同一个分子换一种文本写法，大语言模型是否仍能理解并完成相同任务？作者比较 9 种分子文本表示、8 类任务和 16 个 LLM 配置。研究对象是模型对不同表示的适应能力，不是在这里训练一个新的分子神经网络。

最小实验单元是一道固定问题。把同一分子分别写成 SMILES、IUPAC、CML 等格式，保持题目和模型条件一致，保存实际回答，再与 RDKit 算出的标准答案比较。表示改变后成绩若改变，才得到可检查的实验现象。

已完成与待完成

内容	本次状态
官方来源	作者 arunraja-hub/molrepbench；固定 commit 21d36941cddf0dc1ffb5f3590296592dc68e4ac8
可运行流程	已实现 8 类任务的 9 种表示输入、提示词、推理接口、评分与结果报告入口
离线验证	已生成 270 条 smoke 与 29139 条 paper 请求清单，已完成数据审计与软件测试
真实模型成绩	未运行；需提供本地模型服务或已有 API 配置
全文所有图表	未完成；FCD、原裁判与机制分析有单独依赖或待核实细节

原始论文为用户提供的 arXiv:2606.03057v1，2026 年 6 月 2 日。来源与本项目差异详见第 8 页及 README。软件测试使用的模拟回答只验证程序行为，不是 LLM 化学能力。

九种表示分别在写什么

分子可看作一张图：原子是节点，化学键是边。表示就是把这张图写成模型能读取的文本。格式还可能携带立体、同位素、电荷等信息；并非每个转换实现都保存全部信息。

表示	为何纳入论文比较	阅读与复现时注意
Canonical SMILES	常用紧凑基线，以规范顺序遍历原子	作者转换显式关闭立体信息；“canonical”本身不等于不含立体
Isomeric SMILES	在 SMILES 中加入立体及同位素标记	看能否利用 @、斜线等标记区分立体异构体
Randomized SMILES	同一图使用不同遍历顺序	检验是否依赖固定字符串；本包按 seed 冻结具体输入
DeepSMILES	减少配对括号和环闭合编号的语法困难	语法便利不等于理解更好；作者从非立体 SMILES 转换
IUPAC name	名称中的化学词根与自然语言描述有联系	命名或标准化可能折叠互变形式/电荷态，须验证成员映射
SELFIES	设计上提高合法分子解码的稳健性	合法分子未必满足描述；实际输入仍须完整合法且可解码
MolJSON	用 JSON 显式列出原子和化学键	作者所用 schema 不支持立体；不能推广为所有 JSON 格式都如此
CML	用 XML 显式列出原子、键及属性	更长；转换器与具体字段决定保留哪些化学信息
InChI	分层写出分子式、连接和状态等信息	标准 InChI 可能规范化某些互变形式，不能仅按字符串不同判错

为何不是随便选九种

论文 §3 明确按现代化学信息工具和深度学习中的常用程度选择。它们覆盖常用字符串、为生成而改写的语法、具有语言线索的名称和显式图结构。比较这些选择，可以检验“更常见”“更容易生成”或“图信息更显式”是否真的适合不同任务。

CML/MolJSON 在结构题上可能更容易读取，但更长、成本更高；IUPAC 可能帮助语义对齐，但前提是名称对应正确结构。这里的“可能”是解释假设，不能代替本次实际结果。

八类任务分别测什么

任务	要模型做什么	论文规模与主指标
B1 原子计数	数指定元素 C N O S F Cl 的原子数	200 分子；每分子 1 元素；exact accuracy
B2 官能团	分别判断伯胺、酯、醛、磺酰胺、卤代基是否存在	200 × 5 问；Macro-F1
B3 性质估计	估计 LogP、TPSA、HBD 和 HBA	200 × 4 问；连续性质 Spearman，计数 exact accuracy
B4 分子检索	根据自然语言描述，从四个结构中选一个	78 问；top-1 accuracy
B5 同分子判断	判断两种写法是否代表完全相同的分子	500 对；accuracy；立体异构体为 No
B6 描述生成分子	根据描述生成指定表示的分子	200 描述；有效性、exact match、Tanimoto、FCD
B9 互变异构体	判断两结构是否属于同一规范互变异构体	250 对；accuracy
B10 质子化态	判断中和后是否是同一结构	210 对；accuracy

为何需要不同层次的题

原子计数检验能否读出基本组成；官能团要求识别局部连接关系；性质估计要求从图总结化学特征。检索把结构与自然语言联系起来，生成则反向把描述变成结构。三类成对任务分别考查身份、互变关系与质子化关系，不能混成一个“相似度”问题。

为什么不直接选药效或毒性

论文 §2 的理由是，很多生化性质依赖实验测量及化学或物理归纳偏置。用这些性质评估文本表示，容易混入模型是否掌握相关实验规律的因素。本文选择能由 RDKit 从图计算的 LogP、TPSA、HBD/HBA，让标准答案更可重复。RDKit 算法值也不等于真实实验测量。

B2 的五类标签用于避免过于常见、容易被简单文本线索识别的官能团占主导；具体选择理由见作者 config.py 注释。SMARTS 定义也是实验的一部分，例如作者 halide 模式限定与 sp3 碳连接的卤素，不能自行扩展含义。

零基础需要分清的化学和指标

同一分子不等于同一字符串

例如 CCO 和 OCC 都可写乙醇。它们字符串不同，连接图相同，B5 应回答 Yes。立体异构体连接关系可能相同，却具有不同三维排列，B5 应回答 No。互变异构体涉及氢位置和键重排，B9 才问它们能否归为同一互变家族。酸与去质子化后的阴离子属于 B10 的另一种关系。

四个性质是什么

LogP 描述分子在两种相中的分配倾向，这里采用 RDKit 的 Wildman-Crippen 算法估计。TPSA 是拓扑极性表面积。HBD 是能作为氢键供体的位点数，HBA 是氢键受体位点数；它们不是简单数所有氢、氮或氧。

指标	直观解释	为什么这样用
准确率	答对题数除以计划题数	原子数和离散判断有明确标准答案
Macro-F1	先算五种官能团各自 F1，再平均	让较少出现的官能团也有相同权重；不是总准确率
Spearman 相关	比较预测与真值的排序是否一致	适合 LogP/TPSA 的相对排序；不能说明绝对误差很小
MAE	平均偏差的绝对值	本包作为连续性质的补充指标，不替换论文主指标
Validity	生成串能否解析成合法分子	只检验可解析，不检验是否符合描述
Exact match	生成图是否与参考图相同	主列沿用作者忽略立体的实现，另报含立体列
Tanimoto	比较分子指纹中共同的结构特征	相似不等于完全正确；须说明指纹与无效输出处理
FCD	比较生成集合与参考集合的 ChemNet 分布	是集合指标，不能评价某一个分子，少量样本不稳定

论文正文 §3 与表 2 为 LogP/TPSA 指定 Spearman；附录 D 的“exact match”措辞存在不一致。本包按正文及公开评分代码的连续性质处理，并显式记录这一选择。QED 不属于本论文 B3。

核心代码如何串成一个实验

以 B1 为例，先读入原始 SMILES，让 RDKit 构建分子图并计算参考答案，再把输入换成各表示。LLM 只看任务和该表示文本；标准答案留在本地，等模型回答后评分。

```
counts = chemistry.get_atom_counts(mol)
for rep in reps:
    s = enc(row, rep, mid)
    add(1, mid, element, rep,
        prompts.create_atom_counting_prompt(s, element, rep),
        counts[element])
```

上面节选自 repro/core.py 的实际实现；对失败转换另有 excluded 记录。add 将 ID、表示、实际 prompt、参考答案和 SHA256 写进 manifest。hash 用于确认不同模型是否回答了同一道输入。

```
body = {
  'model': cfg['model'],
  'messages': [{'role': 'user', 'content': item['prompt']}],
  cfg.get('token_parameter', 'max_tokens'):
      cfg.get('max_tokens', 2048)
}
```

这段对应 repro/inference.py 的请求构建逻辑。ground_truth 没有放入 messages。若直接把 RDKit 算出的答案当成“模型结果”，就没有测试 LLM；如果把答案放进 prompt，又会造成答案泄漏。

文件	读它能回答什么
repro/core.py	样本怎么选、9 种表示怎么准备、每道题怎么固定
vendor 的 utils/prompts.py	作者原始任务提示词是什么
vendor 的 config.py 和 chemistry.py	官能团 SMARTS、元素、性质的标准答案怎么定义
vendor 的 representations.py 和 moljson/conversion.py	格式转换保存或丢失了哪些信息
repro/inference.py	模型实际收到什么、如何保存原回答及续跑
repro/scoring.py	如何解析最后答案、计分并保留失败分母

本包的新增工作是便携执行、审计和可追溯评分。作者已有的格式与提示词实现保留来源；不能把整个 vendor 目录称为自己原创。

实际任务提示词如何使用

任务 prompt 沿用作者源码。除输入的分子表示变化外，任务文字保持一致。模型推理开关通过后端配置控制，不能简单删掉“reason step by step”就声称对应论文的 non-reasoning 条件。

一条已经生成的真实 B1 请求

```
How many C atoms are in the following molecule?
Molecule: Nc1ncnc2c1ncn2C1OC(COP(=O)(O)OP(=O)(O)OCC(O)C(=O)O)C(O)C1O

Please reason step by step, and put your final answer within \boxed{}.

Example format: After reasoning, conclude with: The answer is \boxed{42}
```

问题 ID 为 B1:439741:C:canonical_smiles；RDKit 参考答案为 13。这是请求清单中的真实问题；当前尚无模型回答，因此不能给出模型得分。

其他任务的提问形式

任务	作者 prompt 的问题部分
B2	Does the following molecule contain a {functional_group}?
B3	Estimate the {property_display} of the following molecule.
B4	Which of the following molecules matches this description? 后接描述及 A 到 D 四个表示
B5	Do the following two molecular representations refer to the same molecule?
B9	Are the following two molecules tautomeric forms of the same compound?
B10	Are the following two molecules different protonation states of the same compound?

这些题要求把最后数字、Yes/No 或选项字母放入 LaTeX boxed 标记。本包只读取明确的最终答案或纯答案，不把推理正文中随意出现的第一个数字当作答案。

docs/actual_prompt_examples.txt 收录 8 类任务各一条完整 canonical SMILES 实际请求及其参考答案。全部 9 种表示的实际请求在重新运行 prepare 后的 manifest.jsonl。

生成任务与运行步骤

B6 与其他任务有什么不同

B6 的输入是 ChEBI 的自然语言描述，输出才是指定表示的分子。不能把参考 SMILES 作为生成模型的输入。作者额外要求简短回答，避免复述描述；本包沿用同一 generation prompt builder，要求 JSON 格式输出。

```
Given a description of a molecule, generate
the corresponding {rep_name} string.

Description: {description}

For non-MolJSON output:
{"molecule": "..."}
```

MolJSON 则直接输出含 atoms、bonds、charges、aromatic_n_h 的对象，并按作者 schema 约束。其他格式即使包在 JSON 中，内部字符串仍必须是对应分子表示。schema 只约束形状，不能保证化学含义正确。

本地执行顺序

```
python reproduce.py doctor
python reproduce.py verify-vendor
python reproduce.py setup
python -m unittest discover -s tests -v
python reproduce.py prepare --profile smoke --out plans/smoke
python reproduce.py run --plan plans/smoke \
  --settings settings.json --out results/smoke --max-requests 1
```

上述 python 应为项目 .venv 中的解释器。模型服务与 settings 准备好后先调用一条；确认真实响应、token 用量和最后答案，再续跑 270 条 smoke。smoke 只检查链路，不能据此选“最佳表示”。

转入正式比较

先审核 IUPAC 输入，再生成 paper_verified 清单。明确模型、模式与预算后运行正式实验，执行 score、bootstrap 和 report。模型、参数、输入或 seed 改变后建立新结果目录，保留旧结果，不能混在同一份 JSONL 中。

本次公开名称路线共 29139 请求/模型/条件，其中 B5 少 1 个 IUPAC 输入，B10 少 2 个 IUPAC 输入。已审核路线的数量可能更小，需按实际 plan 与共同样本报告。

公开材料的差异与本包处理

可运行不代表与作者当年实验完全相同。以下差异已经检查，必须进入向教授的汇报，不能把它们当作无关的安装问题。

证据	当前处理与含义
B5 的 375 对标签差异	CSV 250 Yes / 250 No 与 RDKit 身份判断一致；本包使用 CSV。作者 runner/evaluator 的 natural/stereoisomer 规则不符合当前 CSV 与同分子问题
B9/B10 的数据源	公开 CSV 全标 ChEBI-20，论文附录 C 写 ZINC250K。保留公开数据来源声明，未重建未核实的 ZINC 实验
预存 SELFIES 成员不匹配	B9 有 183 个、B10 有 118 个成员解码后不等于对应 SMILES。本包非 IUPAC 表示全部从每个成员结构重新生成
互变异构体标签争议	当前 RDKit 默认规则下有 4/250 对不一致，枚举也出现默认限制警告。保留公开标签并记录索引；原因待版本和算法条件核实
IUPAC 名称可能折叠状态	B9 125 对、B10 105 对不同结构共享同名。须借 OPSIN 审核，区分信息折叠与模型错误
解码与采样差异	B6 按论文取 200，公开配置为 250；本包固定随机输入与共同选项顺序，且取消空行停止。都记录为协议改动

如何理解 IUPAC 的审核路线

released 路线保留公开名称，并标为输入未验证。verified 路线只保留 OPSIN 解码后与成员 SMILES 的立体身份完全一致的名称。它不能自动修复坏映射；不一致、网络失败和无法解析各有记录。过滤后必须比较共同样本，不能只比较聚合排名。

“同一个 IUPAC 名称出现在两个状态”本身不必然证明名称错误，但它意味着模型无法只凭该字符串区分这些状态。是否应标准化、是否应保留某种差异，是任务定义和表示能力的问题。

怎样解释未来得到的成绩

先看证据完整性

查看预定条数、实际调用成功数、最终答案解析率及解码状态。API 成功返回并不保证有最终答案；finish_reason 为 length 表示可能截断。IUPAC 未联网解码时应标未评估，不记为无效分子。

再看公平比较

比较表示时使用同一模型、相同问题和可比较的推理/解码条件。不同表示有缺失时，应在共同问题 ID 上做配对比较，并同时报告完整计划覆盖率。不同模型或样本规模的两行成绩，不能直接用来证明表示带来的差异。

连续性质仅在可解析数字上计算 Spearman 和 MAE，须同时显示覆盖率。官能团若有无法解析的回答，本包不填主 Macro-F1，只给 valid-only 值作参考及全体准确率。离散题的缺答案按计划分母计错。

论文结论与我的结果要分开

原论文报告 CML/MolJSON 更适合某些结构任务、IUPAC 更适合语义任务，并强调没有一种表示在所有任务上最好。这是论文作者在其模型和设置下的观察。我的正式实验只有实际跑完并保存证据后，才能说明是否支持同样的趋势。

若趋势不同，先检查标签、数据源、格式转换、模型版本、推理模式、token 预算、schema、样本缺失和评分定义。排除实现差异后，再讨论模型本身的变化。不能直接把差异解释为我改进了原论文。

哪些内容仍然属于扩展范围

部分	完成它需要什么
FCD	真实生成结果、ChemNet 依赖和权重、足够样本；本次未计算
LLM 裁判	对齐论文 Gemini 3 Flash、样本与 rubric；本包 judge 是标注清楚的改编入口
Tokenizer 审计	实际 tokenizer 与固定分子样本；提供入口但尚未下载/运行
线性探针与注意力	核实层、span、池化、训练划分及 GPU；公开文件未提供可直接重放全部图的完整流程

这些项目不应因为主任务脚本跑通而自动标为成功。项目状态文件始终把全文复现状态与主任务执行分开。

向教授汇报时怎样说清楚

目前可以如实汇报的版本

我已找到原论文的作者仓库，核对了九种分子表示、八类任务及实际提示词。我把作者代码和公开数据固定到一个 commit，并实现了可以在本地 Python 环境运行的流程。现在完成的是数据、提示词和软件验证，还没有运行真实模型，所以还不能报告 LLM 复现成绩。

我理解这篇论文是在测试“分子的写法会不会改变模型的能力”。我会固定分子、题目和模型，改变表示，再保存原始回答并与 RDKit 标准答案对比。原子计数测基本解析，官能团与性质估计测结构推理，检索和生成测语言与结构的联系，成对任务则区分身份、互变异构体和质子化关系。

审读代码后我发现，公开脚本的 B5 标签读取与数据不一致，部分分子对预存表示也需要重新生成。公开 B9/B10 的数据源说明与论文有差异。我会明确记录这些修正，因此当前计划是公开材料的审计复现，不先声称逐个数值重现作者表格。

运行成功后再补充的内容

实际报告中补入精确模型版本、运行条件、完成条数、每种表示成绩、缺失分母、置信区间和真实失败案例。口述时选一道真实题，展示它的 SMILES、变换后的输入、实际 prompt、模型原始回答、标准答案与评分，逐步解释每一项。不要在这些证据产生前写“我成功验证了某表示最好”。

教授可能追问的具体问题

问 为什么选这些任务?

答 任务覆盖组成、局部图、图属性、语言对齐与不同化学等价关系；标准答案大多可以计算，便于把差异追溯到表示和模型。

问 你的核心代码和 prompt 在哪?

答 prepare 生成清单，作者 prompts.py 决定任务措辞，inference.py 只发送 prompt，scoring.py 按保存的原始回答重新计分。可现场打开同一 ID 的完整链路。

问 这是否已经完整复现?

答 当前没有真实 LLM 结果；后续也必须分别说明主任务、模型覆盖、FCD、裁判和机制研究的完成状态。数据与协议偏差会保留，不用“全部完成”掩盖。

来源索引 论文 §2 §3 §4 §6 附录 C D E H I J；作者仓库固定 commit；README；UPSTREAM_PROVENANCE.json；evidence/dataset_audit.json。联网来源 https://arxiv.org/abs/2606.03057 和 https://github.com/arunraja-hub/molrepbench。