# MolRepBench 论文复现：离线成果与协议说明（模型实验未完成）

本文档基于本地实际运行的产物生成，不含任何未经运行的成绩声明。 模型实验状态：未完成——所用 DeepSeek 密钥被服务端判定为无效（HTTP 401, key ****d522 is invalid）， 连 GET /user/balance 亦同样失败，属账号侧问题，不是本次代码或参数问题。

---

## 1. 复现目标与范围

- 论文：*Rethinking Molecular Text Representations for LLMs: An Empirical Study*（arXiv:2606.03057v1）。
- 核心问题：同一个分子有多种"写法"（9 种文本表示）。固定题目与模型，只改变表示，观察 LLM 答题是否改变。这不是训练新的分子模型，LLM 权重不变；RDKit 只是用来转换格式和计算标准答案的工具。
- 范围：9 种表示 × 8 类任务（B1 原子计数、B2 官能团、B3 性质估计、B4 描述检索、B5 同分子判断、B6 描述生成分子、B9 互变异构体识别、B10 质子化态识别）。
- 本次实际完成：环境、计划生成、数据审计、IUPAC 名称审核、协议偏差记录、代码审读。本次未完成：真实模型回答、成绩、FCD、LLM 裁判、§6 机制分析、paper 级 29139 请求。

## 2. 来源、固定 commit 与许可

| 项目 | 内容 |
| --- | --- |
| 作者仓库 | https://github.com/arunraja-hub/molrepbench |
| 固定 commit | 21d36941cddf0dc1ffb5f3590296592dc68e4ac8 |
| 本地校验 | verify-vendor：32 个跟踪文件 SHA256 全部一致，vendor 未被修改 |
| 数据 | benchmark_data_small.zip 内 9 个 CSV（ChEBI-20 测试集、分子对、检索干扰项等） |
| 许可 | 该 commit 未包含 LICENSE 文件；本复现不重新授权作者材料，公开发布前需核实许可 |

作者代码 vs 本次新增：

- 作者原始代码：vendor/molrepbench/（prompts、representations、config、evaluate、tabulate_results、qualitative_eval 等）， 本次零修改**。
- 本次新增：repro/（便携运行器）、tools/（诊断与密钥注入脚本）、evidence/**（本次证据）。

## 3. 环境与平台偏差（CML 的真实问题与解决）

| 项 | 值 |
| --- | --- |
| 实际执行环境 | conda 环境 molrep：Python 3.12.15、Windows 11、rdkit 2025.9.6、selfies 2.2.0、deepsmiles 1.0.1、numpy 2.3.5、scipy 1.16.2、pandas 2.2.3 |
| 备用环境 | 项目内 .venv（Python 3.12.14 + requirements.txt 全量 pin，含 openbabel-wheel 3.1.1.23） |
| GPU | GTX 1650 4GB，无法本地部署论文中 4B – 235B 模型；本机无本地 LLM 服务 |

平台问题（实测，非推测）：

1. PyPI openbabel-wheel 3.1.1.23 在 Windows 注册了 137 个格式，但没有 cml（输入输出皆无）。 而作者的 smiles_to_cml() 走 mol.write("cml")，因此在 Windows 上所有 CML 输入都会生成失败。 2. conda-forge openbabel 3.2.1（Windows）也没有 cml 格式。 3. conda-forge openbabel 3.1.1（Windows）有 cml（CLI obabel -L formats 列出 cml -- Chemical Markup Language），但其 Python 绑定在进程内无法加载 formats_common.obf / formats_xml.obf 插件（pybel.informats 为空或缺 smi）。

解决方式（保持"真实 CML"，绝不用 SMILES 冒充）：按 README 许可的回退方案，改用 conda-forge 的 OpenBabel 3.1.1（与 wheel 内含的 OB 版本相同），并在 repro/core.py 中按作者自己的做法 （vendor/.../representations.py::cml_to_smiles 本来就 subprocess 调用 obabel 可执行文件） 增加平台适配：CML 生成/解析走 obabel CLI。

实测验证：C[C@H](O)c1ccccc1 → CML → SMILES 往返后立体化学完全保留； 带电分子 CML 含 formalCharge；垃圾输入判为 invalid 而非崩溃。

## 4. 数据、样本 ID 与排除项

计划
请求数
8 任务 × 9 表示
排除项
manifest SHA256（前 16 位）

plans/smoke
270
全部覆盖
0
b99adf64cb0a311a

plans/paper
29139
全部覆盖
3（IUPAC 缺名）
444029bc73dfa9b5

plans/paper_verified
27654
全部覆盖
928（IUPAC 未通过审核）
d17d6e3a2556690c

smoke/paper 的 manifest 哈希与交付环境记录逐位一致，说明本地重算（含 CML 适配）产生了逐字节相同的提示词。
3 个排除项（plans/paper/excluded.jsonl）：B5:355、B10:170、B10:195，原因均为 pair_conversion_failed——公开数据缺 IUPAC 名称，不做任何填补。
任务规模（paper 计划，公开名称路线）：

任务
每种表示的请求数
含义

B1
200
200 分子 × 1 个元素计数问题

B2
1000
200 分子 × 5 个官能团

B3
800
200 分子 × 4
个性质（LogP/TPSA/HBD/HBA）

B4
78
78 个四选一检索问题

B5
500（IUPAC 499）
500 个分子对：250 同分子(Yes)、125
立体异构(No)、125 取代(No)

B6
200
200 条描述生成分子

B9
250
互变异构体对

B10
210
质子化态对

理解力子集：200 个分子（MW ≥ 302.3、环数 ≥ 2），从 ChEBI-20 测试集 3297 个分子中分层抽样。

## 5. 九种表示：各编码什么、保留什么（实测长度佐证）

表示
编码内容
立体
电荷
互变形式
实测平均字符数

Canonical SMILES
RDKit 规范序的 SMILES（不含立体）
否
是
不区分

70
Isomeric SMILES
含 @/@@、/\ 的 SMILES
是
是
不区分
100
Randomized SMILES
同一分子的随机书写顺序（固定 seed）
否
是
不区分
73
DeepSMILES
去掉环闭合数字与括号的 SMILES 变体
否
是
不区分
74
IUPAC
系统命名（自然语言式化学语义）
名称可含 (R/S)
名称可含 ion
会标准化掉
158
SELFIES
100% 鲁棒编码，语法合法即对应分子
是
是
归一到同一分子
341
MolJSON
显式 atoms/bonds 数组的图序列化
不支持
是
不区分
2888
CML
Chemical Markup Language，XML
原子/键列表 + 立体
是（atomParity）
是（formalCharge）
不区分
4363
InChI
规范化哈希串（分层：骨架/连接/立体/同位素层）
部分层
是
归一
228

为什么要选这些：它们覆盖了"从紧凑哈希到自然语言、再到显式图"的不同编码风格，
同样的信息被压缩/展开的程度不同，因此可以检验"表示形式是否影响 LLM 答题"。
数据来自 evidence/representation_length_stats.json：CML 平均比 canonical SMILES 长 62 倍， 最大一条 B5 的 CML 达 42398 字符——这正是运行时要重点观察截断的原因。

## 6. 八类任务：测什么、为何能区分表示、用什么指标

任务
测什么
为何能区分表示
主指标
B1 原子计数
数某种元素的原子个数
需要逐字符扫描，长表示更易丢细节
exact accuracy
B2 官能团识别
是否含 5 个指定官能团之一
IUPAC 里是词（"amine"），SMILES 里是子结构匹配
Macro-F1（5 标签）
B3 性质估计

LogP/TPSA/HBD/HBA
需要把结构映射到物理量，语言线索强弱不同
LogP/TPSA 用 Spearman；HBD/HBA
用整数准确率

B4 描述检索
4 个分子中哪个匹配描述
描述是自然语言，需跨表示匹配
top-1 accuracy

B5 同分子判断
两个写法是否同一分子
立体异构体在 canonical SMILES
下完全相同，在 isomeric/CML/InChI
下不同
accuracy

B6 描述生成分子
从描述生成目标表示
输出长度与格式合规差异巨大
validity / exact match / 三类
Tanimoto（FCD 未做）

B9 互变异构体
是否互变异构
只有部分表示保留互变差异
accuracy

B10 质子化态
是否不同质子化态
电荷在部分表示中才可见
accuracy

关键设计点：B5 的 canonical SMILES 条件天然"看不到"立体差异，
因此"同分子判断"在不同表示下应当有系统性差异——这正是论文的论点。

## 7. 核心代码（作者原始代码与本次实现的分工）

作者 repro/core.py::prepare（本次未改 vendor，复用其 prompts）：
add(1, mid, element, rep, prompts.create_atom_counting_prompt(s, element, rep), counts[element])
for group, definition in config.FUNCTIONAL_GROUPS.items():
truth = chemistry.has_substructure(mol, definition['smarts'])
add(2, mid, group, rep, prompts.create_functional_group_prompt(s, definition['name'], rep), truth)

本次新增的 CML 平台适配（repro/core.py）：
if representation == 'cml':
value = rep.convert_to_representation(smiles, 'cml') # 作者原生路径（Linux 行为）
if value:
return value
return cml_from_smiles(smiles) # Windows 回退：obabel CLI

推理只发 prompt，不发答案（repro/inference.py）：
body = {'model': cfg['model'], 'messages': [{'role': 'user', 'content': item['prompt']}],
cfg.get('token_parameter', 'max_tokens'): cfg.get('max_tokens', 2048)}

参考答案 ground_truth 只保留在 manifest，评分阶段才使用（测试 test_ground_truth_not_in_request_fields 守护这一点）。
评分严格取最后一个 \boxed{}（repro/scoring.py）：
boxes = re.findall(r'\\boxed\{([^{}]*)\}', text)
if boxes:
return boxes[-1].strip()

不会从推理过程里随便抓一个数字当答案；缺失与失败计入分母，不删除。

## 8. 每类任务的实际 prompt（来自本地 manifest，模型未运行）

B1 原子计数（B1:439741:C:canonical_smiles，参考 13）：
How many C atoms are in the following molecule?
Molecule: Nc1ncnc2c1ncn2C1OC(COP(=O)(O)OP(=O)(O)OCC(O)C(=O)O)C(O)C1O
Please reason step by step, and put your final answer within \boxed{}.

B2 官能团（同分子问 primary amine，参考 True）：
Does the following molecule contain a Primary amine?
Molecule: Nc1ncnc2c1ncn2C1OC(COP(=O)(O)OP(=O)(O)OCC(O)C(=O)O)C(O)C1O
Please reason step by step, and put your final answer (Yes or No) within \boxed{}.

B3 性质（LogP，参考 -2.276）：

Estimate the LogP (partition coefficient) of the following molecule.
Molecule: Nc1ncnc2c1ncn2C1OC(COP(=O)(O)OP(=O)(O)OCC(O)C(=O)O)C(O)C1O
Please reason step by step, and put your final answer (a number) within \boxed{}.

B4 检索（参考 A）：
Which of the following molecules matches this description?
Description: The molecule is a nucleotide-aldonic acid, ...
A: Nc1ncnc2c1ncn2C1OC(COP(=O)(O)OP(=O)(O)OCC(O)C(=O)O)C(O)C1O
B: ... C: ... D: ...
Please reason step by step, and put your final answer (only the choice letter) within \boxed{}.

B5 同分子（参考 True）：
Do the following two molecular representations refer to the same molecule?
Molecule 1: CC(=O)C(O)C(O)C(=O)COP(=O)(O)O
Molecule 2: CC(=O)C(O)C(O)C(=O)COP(=O)(O)O
Please reason step by step, and put your final answer (Yes or No) within \boxed{}.

B6 生成（参考 COC(=O)/C=C1/CC[C@H]2...）：
Given a description of a molecule, generate the corresponding Canonical SMILES string.
IMPORTANT: Don't restate the full description ... Output tokens are limited ...
Description: The molecule is a steroid ester that is methyl (17E)-pregna-4,17-dien-21-oate ...
Your final output must be a JSON object in this format:
{"molecule": "..."}

B9 互变异构（参考 True）：
Are the following two molecules tautomeric forms of the same compound?
Molecule 1: C=C(C)C1C=CC(C)C(=O)C1
Molecule 2: C=C(C)C1C=C(O)C(C)=CC1
Please reason step by step, and put your final answer (Yes or No) within \boxed{}.

B10 质子化（参考 True）：
Are the following two molecules different protonation states of the same compound?
Molecule 1: NCc1[nH]cc(CCC(=O)O)c1CC(=O)O
Molecule 2: NCc1[nH]cc(CCC(=O)[O-])c1CC(=O)O
Please reason step by step, and put your final answer (Yes or No) within \boxed{}.

由于模型实验未完成，以上没有模型原始回答与得分。任何声称"模型答对/答错"的表述都会是编造。

## 9. IUPAC 输入审核（本次最重要的离线发现）

公开数据里，同一个分子对的两个成员常常共用同一个 IUPAC 名称（B9 有 125 对、B10 有 105 对）。 用 OPSIN（名称解析服务，不是 LLM）逐个解析 4551 个 (SMILES, IUPAC) 成员：

结果
数量
含义
与成员 SMILES 立体身份完全一致
2697（59%）
名称忠实表示该成员
连接性一致但立体不一致
41
名称把立体信息折叠掉了
不一致
1567
名称标准化成了另一种形式（互变/电离/其它结构）
无法解析
287
名称本身不合法或 OPSIN 不认

结论：不能把公开 IUPAC 名称当作"该成员的忠实写法"。 区分三件事很重要：① 表示本身丢信息（信息损失）；② 名称映射到别的分子（数据问题）；③ 模型能力不足。本次只回答了 ①②，③ 需要真实模型运行才能回答。 verified 路线（plans/paper_verified）只保留 2697 条通过审核的 IUPAC 输入，总请求降到 27654， B4 的 IUPAC 只剩 11/78、B9 44/250、B10 45/210。报告必须同时给出两条路线的分母。

## 10. 协议偏差与数据疑点（如实记录，不掩盖）

事项
处理
对结论的影响
B5 标签
采用 CSV ground_truth（250 Yes / 125

立体异构 No / 125 取代
No）；作者代码的 natural/stereoisomer
规则与之在 375/500 上冲突
不等于原表严格重放

B5 与当前 RDKit
CSV 标签与当前 RDKit 立体身份判断
500/500 一致
保留 CSV 标签

B9 争议
4/250 对与当前 RDKit
默认互变枚举不一致；在 10000
上限下仍不一致
保留公开标签，成因待作者澄清

B10
与当前 RDKit 一致（0 冲突）
—

B9/B10 数据源
CSV source 全为 ChEBI-20，论文称
ZINC250K
未证实为同一数据

预存 SELFIES
B9 有 183 个、B10 有 118 个"成员 SELFIES
与成员 SMILES 不匹配"
所有非 IUPAC 表示均从成员 SMILES
重新生成

B6 样本数
用 200（论文附录 C），仓库配置为 250
样本规模不可混用

B4 选项顺序
同一问题在 9 种表示下顺序一致
便于配对比较（协议改动）

停止序列
不使用作者代码的 \n\n 早停
避免答案被空行截断

IUPAC
公开名称路线 vs OPSIN 审核路线并列
分母不同，成绩不可混用

模型
DeepSeek 官方 deepseek-chat（非论文 15
模型之一）、prompt_only、temperature
0.6 / top_p 0.95 / max_tokens 2048、未控
seed
partial reproduction

Windows CML
见第 3 节平台适配
输入字节与论文一致（manifest
哈希相同可证）

## 11. 本次完成 / 未完成 / 替代实现

已完成：Python 3.12 环境与依赖（含 CML 可用）、verify-vendor 32/32、11 项单元测试通过、 smoke 270 与 paper 29139 计划（哈希与交付一致）、离线审计重跑（与交付逐字段一致，含 RDKit 枚举警告）、 OPSIN 全量 IUPAC 审核与 verified 路线、B9 标签敏感性、9 种表示长度统计、裁判与 tokenizer 边界审读。
未完成：真实模型回答与任何成绩、FCD、LLM 裁判、 §6 线性探针/注意力分析、paper 级 29139 请求、多模型扩展、thinking on 条件。
替代/新增实现：repro/core.py 的 Windows CML 适配、tools/prefetch_iupac.py（并行 OPSIN 预取，只预热同一缓存，输出与原 audit --iupac 一致）、tools/run_with_key.py（getpass 密钥注入）、tools/api_probe.py、tools/key_shape_check.py、tools/key_validity_test.py。

## 12. 可复制的运行命令（Windows）

```
cd C:\Users\Asus\Desktop\molrepbench\molrepbench_reproduction
$PY = "C:\Users\Asus\miniconda3\envs\molrep\python.exe"
& $PY reproduce.py doctor
& $PY reproduce.py verify-vendor
& $PY reproduce.py setup
& $PY -m unittest discover -s tests -v
& $PY reproduce.py prepare --profile smoke --out plans/smoke
& $PY reproduce.py prepare --profile paper --out plans/paper
```

```
& $PY reproduce.py audit --output evidence/audit_rerun.json
& $PY tools\prefetch_iupac.py
& $PY reproduce.py audit --iupac --output evidence/audit_with_iupac.json
& $PY reproduce.py prepare --profile paper --iupac-policy verified --out plans/paper_verified
# 模型实验（需要有效密钥；密钥经隐藏输入，不落盘）
& $PY tools\run_with_key.py tools\api_probe.py
& $PY tools\run_with_key.py reproduce.py run --plan plans/smoke --settings settings.json --out results\deepseek-chat_off_smoke
--max-requests 1
& $PY tools\run_with_key.py reproduce.py run --plan plans/smoke --settings settings.json --out results\deepseek-chat_off_smoke
& $PY reproduce.py score --plan plans/smoke --run results\deepseek-chat_off_smoke --allow-network
& $PY reproduce.py bootstrap --run results\deepseek-chat_off_smoke --samples 10000
& $PY reproduce.py report --run results\deepseek-chat_off_smoke --out reports\deepseek-chat_off_smoke
```

## 13. 向教授口述稿（2 – 3 分钟，尚未跑通模型实验的版本）

我复现的是论文《Rethinking Molecular Text Representations for LLMs》的实验协议。
它的想法很简单：同一个分子有九种"写法"，比如规范 SMILES、带立体的 SMILES、DeepSMILES、 SELFIES、IUPAC 名称、MolJSON、CML、InChI、随机 SMILES。我们固定题目和模型，只改变写法，
看大模型的答题会不会变。这不是训练新的分子模型，模型权重不变；RDKit 只是用来转换格式、
算标准答案的工具，标准答案从不发给模型。 我已经用作者公开仓库的固定 commit
复现了完整的数据与评测流程：九种表示、八类任务， 生成了 270 条冒烟计划和 29139
条完整计划，两者的提示词哈希与交付方记录逐位一致； 单元测试 11 项全过，数据审计与交付方结果完全相同。
过程中我发现三件值得报告的事。第一，Windows 上常用的 openbabel-wheel 根本不含 CML 格式， 直接跑会让 CML 全部失败；我按作者自己的做法改用同版本的 OpenBabel 命令行接口， 保证输入是真正的 CML 而不是拿 SMILES 冒充。第二，公开数据里 125 对互变异构体、105 对质子化态 共用同一个 IUPAC 名称；我用 OPSIN 逐条解析 4551 个成员，只有 2697 个名称与该成员的立体身份完全一致， 也就是说 IUPAC
这条线的输入本身就不可靠，所以我保留了两条路线和各自的分母。 第三，B9 有 4 对标签在当前 RDKit
互变异构枚举下对不上，我做了敏感性检查：把枚举上限提高一万倍
结果仍然对不上，所以这不是计算上限造成的，成因需要向作者确认，我没有擅自改标签。
真实模型实验还没有完成：我用的 DeepSeek 密钥被服务端判为无效，连查余额接口都返回 401，
这是账号侧问题，不是代码问题。我已经把提示词、评分口径、失败处理、断点续跑都验证过，
密钥一换就能立刻跑完全部 270 条并给出成绩。到那时我才会说"复现了"， 现在我只能说：流程和证据已经就绪。

## 14. 教授可能追问的问题与基于本次证据的回答

追问
基于本次证据的回答

你真的跑过模型吗？
没有。results/deepseek-flash_off_smoke/
里只有 2 条 HTTP 401
失败记录，如实保留。没有任何成绩数字。

为什么不改用能跑的模型？
硬件限制：4GB 显存跑不了论文的
4B – 235B 模型；预算限制：本次仅
smoke 270 条。

你的数据和论文一样吗？
计划哈希一致，但 B9/B10 的 source
字段写的是 ChEBI-20，论文说
ZINC250K，未证实同源；B6 用 200
而仓库配置是 250。

canonical SMILES 不是丢立体了吗？
是的，这正是 B5
的设计意图：不带立体的表示会让立体异构体对变成"同一个分子"，带立体的表示才能区分。

SELFIES 100% 合法，是不是最简单？
合法不等于答对。它把同一分子的多种写法归一到相近串，可能让"识别差异"的任务变简单，但不保证化学判断正确。

CML/MolJSON
更长，会不会只是长度效应？
有这个风险。实测 CML 平均是 SMILES
的 62 倍、B6 输出最长 20450 字符，2048
token 上限必然截断；所以要看
finish_reason=length
的比例，不能只看准确率。

你的 IUPAC 结果能说明模型不行吗？
不能。59%
的公开名称本身就与成员结构不一致，这属于数据问题，必须先与"模型能力"分开。

为什么用 Spearman 而不是准确率？
LogP/TPSA

是连续量，模型给的是估计值，只有排序相关才有意义；HBD/HBA
是整数，才用准确率。

这些分数能和论文表格比吗？
不能直接比。模型不同（partial
reproduction）、样本仅 270、IUPAC
分母不同。只能说"在同一协议下测了同一批表示与任务"。

样本量 270 够吗？
不够做科学结论，只够验证链路。每任务每表示仅
2
个分子或分子对，任何排名都不能当结论。

## 15. 证据索引

见 evidence/ARTIFACT_INDEX.md（来源、环境、计划、审计、模型运行、边界六类，含每个文件的含义）。