MolRepBench 论文复现：完成情况与阻塞说明

项目：C:\Users\Asus\Desktop\molrepbench\molrepbench_reproduction 论文：*Rethinking Molecular Text Representations for LLMs: An Empirical Study*（arXiv:2606.03057v1） 作者仓库：https://github.com/arunraja-hub/molrepbench 固定 commit：21d36941cddf0dc1ffb5f3590296592dc68e4ac8 日期：2026-10-20

---

0. 一句话结论

离线部分（环境、数据、提示词、审计、审核、协议偏差）已全部实现并用实际运行验证；
唯一没做成的是"真实模型问答"，原因是所提供的 DeepSeek 密钥被官方服务端判定为无效，
且该失败与本次代码、参数、网络无关——需要你在 DeepSeek 控制台侧解决。
因此本项目没有任何模型成绩，也没有声称复现了论文任何一行结果数字。

1. 阻塞点：为什么模型实验停下

1.1 现象

运行真实请求时，服务端返回：
POST https://api.deepseek.com/chat/completions
HTTP 401
{"error":{"message":"Authentication Fails, Your api key: ****d522 is invalid",
"type":"authentication_error","code":"invalid_request_error"}}

1.2 我做的排查与证据

排查动作	结果	排除了什么
verify-vendor 校验作者代码	32/32 文件哈希一致，代码未被破坏	代码被改动
检查请求体	model/max_tokens/temperature/top_p 均为合法值	参数名写错
tools/api_probe.py（最小请求）	同样 401	请求体过于复杂
tools/key_shape_check.py	长度 35、sk- 前缀、正文为 32 位十六进制、无杂字符	复制残缺、带引号、混入空格
tools/key_validity_test.py（GET /user/balance）	同样 401 invalid	模型名、请求体、schema、网络、代理

最后一条是决定性的：查询账户余额的接口根本不带任何模型参数，
仍然被拒，说明失败发生在身份认证阶段，尚未进入模型路由。

1.3 结论

- 这把密钥在 DeepSeek 服务端不被承认：可能已被撤销/删除、属于另一个账号，
或不是 API 控制台签发的密钥（例如来自 App 登录态、其他服务的中转密钥）。
- 你在聊天中粘贴的这把密钥与被拒的密钥结尾相同（均为 d522），是同一把，
重新粘贴不会改变结果。
- 安全提醒：该密钥已出现在聊天记录中，等同于泄露，建议在控制台删除并轮换。

1.4 我没有做什么（重要）

- 没有伪造任何模型回答，没有用测试夹具（fixture）冒充模型输出。
- 没有把失败样本从分母里删掉；两条 401 记录保留在
results/deepseek-flash_off_smoke/raw.jsonl 中。
- 没有为了让流程"跑通"而更换模型、降低任务难度或删除困难表示。

1.5 恢复需要你做的事（二选一）

1. 在 <https://platform.deepseek.com> 控制台新建密钥，然后在本机运行：
cd C:\Users\Asus\Desktop\molrepbench\molrepbench_reproduction
C:\Users\Asus\miniconda3\envs\molrep\python.exe tools\run_with_key.py tools\api_probe.py

看到 HTTP 200 后即可继续单请求验证 → 全量 270 条 → 评分 → 正式报告。
2. 或改用任何其它 OpenAI 兼容服务：只需告诉我 base_url 与精确 model ID， 我改 settings.json
并用新的结果目录继续（密钥仍由你在终端隐藏输入）。

2. 已完成的工作总览

阶段
状态
关键产出/结果

1. 环境
完成
Python 3.12.15 conda 环境 molrep（rdkit 2025.9.6 + 全部固定版本）；项目内 .venv 亦已创建

2. 平台问题处理
完成
Windows 上 CML 双向转换打通（详见 §3.1）

3. 离线验证
完成
verify-vendor 32/32；setup 解出 9 个数据文件；11 项单元测试全过

4. 计划生成
完成
smoke 270、paper 29139、paper_verified 27654（详见 §3.2）

5. 数据审计
完成
重跑结果与交付环境逐字段一致；RDKit 枚举警告已保存

6. IUPAC 审核
完成
4551 个成员经 OPSIN 解析，仅 2697 个与成员立体身份一致（详见 §3.3）

7. 标签敏感性
完成
B9 4 个争议标签在枚举上限提高一万倍后仍不一致

8. 代码审读
完成
论文原裁判（Gemini 3 Flash 等）与 token_audit 边界已记录

9. 交付文档
完成
本文档 + 离线成果报告（DOCX/PDF）+ 证据索引 + 口述稿

10. 模型实验
阻塞
密钥无效，见 §1

3. 三个值得单独汇报的技术发现

3.1 Windows 上 CML 完全不可用（真实平台缺陷，已解决）

- PyPI openbabel-wheel 3.1.1.23（Windows）注册 137 个格式，没有 cml。
- conda-forge openbabel 3.2.1（Windows）也没有 cml。
- conda-forge openbabel 3.1.1（Windows）有 cml，但其 Python 绑定在进程内无法加载 formats_common.obf / formats_xml.obf 插件（pybel.informats 为空）。
- 作者的 smiles_to_cml() 依赖 mol.write("cml")，在上述任一 Windows 环境都会失败，导致 CML 整条表示线缺失。
- 解法：按 README 允许的回退方案改用 conda-forge OpenBabel 3.1.1，并在 repro/core.py 中以作者自己 cml_to_smiles() 的做法（subprocess 调 obabel）增加平台适配。始终使用真实 CML，没有用 SMILES 冒充 CML。
- 验证：C[C@H](O)c1ccccc1 → CML → SMILES 往返后立体化学完全保留；带电分子保留 formalCharge；非法输入判为 invalid 而非崩溃。
- 旁证：修复后重新生成的 smoke 与 paper 计划 manifest SHA256 与交付环境记录逐位一致，说明输入字节与原论文环境相同。

3.2 计划可复现性核对

计划
请求数
排除项
manifest SHA256（前 16 位）
与交付记录

smoke
270
0
b99adf64cb0a311a
一致

paper
29139
3（B5:355、B10:170、B10:195，均为
IUPAC 缺名）
444029bc73dfa9b5
一致

paper_verified
27654
928（IUPAC 未过审核）
d17d6e3a2556690c
本次新增

三份计划均覆盖 8 类任务 × 9 种表示（verified 路线的 IUPAC 列样本减少，非 IUPAC 列不变）。

3.3 IUPAC 输入本身不可靠（本次最重要的数据发现）

公开数据中，B9 有 125 对、B10 有 105 对两个成员共用同一个 IUPAC 名称。 用 OPSIN（名称解析服务，非 LLM）解析全部 4551 个 (SMILES, IUPAC) 成员：

结果
数量
占比

与成员 SMILES 立体身份完全一致
2697
59%

连接性一致但立体不一致
41
0.9%

不一致（名称标准化成了别的形式）
1526
33.5%

无法解析
287
6.3%

含义：公开 IUPAC 名称不能当作"该成员的忠实写法"。 必须区分三件事：① 表示本身丢信息；② 名称映射到别的分子（数据问题）；③ 模型能力不足。 本次只回答了 ①②；③ 需要真实模型运行才能回答。 因此报告必须并列两条路线与各自的分母，不能混用。

4. 其它已核实的事实（可用于答辩）

- B5 标签采用 CSV ground_truth（250 Yes / 125 立体异构 No / 125 取代 No）；
作者代码的 natural/stereoisomer 规则与之在 375/500 上冲突，本次不恢复该错误规则。
- B5 的 CSV 标签与当前 RDKit 立体身份判断 500/500 一致。
- B9 有 4/250 对与当前 RDKit 默认互变枚举不一致；提高枚举上限后仍不一致，
成因需向作者澄清，本次未擅自改标签。
- B9/B10 预存 SELFIES 与成员 SMILES 不匹配的成员数分别为 183 / 118，
所有非 IUPAC 表示均从成员 SMILES 重新生成，未回退到错误列。
- B9/B10 的 source 字段全部为 ChEBI-20，论文称 ZINC250K，未证实同源。
- B6 论文为 200 条、仓库配置为 250 条，本次取 200 并记录差异。
- 9 种表示的实测平均字符数：canonical SMILES 70、randomized 73、DeepSMILES 74、
isomeric 100、IUPAC 158、InChI 228、SELFIES 341、MolJSON 2888、CML 4363。 B6 中 MolJSON 参考答案最长 12393 字符、CML 最长 20450 字符， 在 2048 token 上限下必然存在截断风险，跑完需按 finish_reason 核对。

5. 交付物清单

路径
内容

evidence/REPORT_OFFLINE_FINDINGS.md
/
reports/offline/REPORT_OFFLINE_FINDINGS.docx
/ .pdf
复现范围、来源、环境、表示与任务解释、核心代码、真实 prompt、协议偏差、未完成清单、口述稿、教授追问

evidence/ARTIFACT_INDEX.md
全部证据文件索引与含义

evidence/settings_decisions.md
模型配置决策与偏差（partial

reproduction 依据）

evidence/review_vendor_boundaries.md
论文原裁判与 token_audit
的边界（本次均未运行）

evidence/doctor_output.json、unittest_run.txt、pip_freeze_conda_molrep.txt、conda_list_molrep.txt
环境与测试证据

evidence/audit_rerun.json、audit_rerun_log.txt、iupac_audit_final_log.txt
数据审计与 RDKit 枚举警告

evidence/iupac_input_audit.json、b9_label_sensitivity.json、representation_length_stats.json
IUPAC 审核、标签敏感性、长度统计

plans/smoke、plans/paper、plans/paper_verified
三份计划（prompt、参考答案、prompt
哈希）

results/deepseek-flash_off_smoke/raw.jsonl
失败记录（2 条 HTTP 401），保留不删

tools/run_with_key.py、api_probe.py、key_shape_check.py、key_validity_test.py、prefetch_iupac.py、md_to_docx_pdf.py
本次新增工具（密钥不落盘）

vendor/molrepbench/**
作者原始代码，零修改

6. 未完成清单（不得表述为已完成）

1. 真实模型回答与全部成绩（阻塞于密钥）。 2. FCD（需要额外依赖与 ChemNet 权重，本次未安装、未计算）。 3. LLM 裁判（需要 Gemini 密钥与多模型 B6 结果；repro 的 judge 是改编 rubric， 不能声称等同论文原裁判）。 4. §6
机制分析（线性探针、注意力重放）：公开的 32 个文件中未找到可完整重放的实现，
需向作者确认模型、样本、层、池化、划分等细节；本包 tools/token_audit.py 只做 tokenizer 长度审计，不是机制图复现。
5. paper 级 29139 请求、thinking on 条件、多模型扩展（预算仅 smoke 270）。

7. 恢复执行清单（密钥可用后按顺序）

```
cd C:\Users\Asus\Desktop\molrepbench\molrepbench_reproduction
$PY = "C:\Users\Asus\miniconda3\envs\molrep\python.exe"
& $PY tools\run_with_key.py tools\api_probe.py # 必须 HTTP 200
& $PY tools\run_with_key.py reproduce.py run --plan plans/smoke --settings settings.json --out results\deepseek-chat_off_smoke
--max-requests 1
& $PY tools\run_with_key.py reproduce.py run --plan plans/smoke --settings settings.json --out results\deepseek-chat_off_smoke
& $PY reproduce.py score --plan plans/smoke --run results\deepseek-chat_off_smoke --allow-network
& $PY reproduce.py bootstrap --run results\deepseek-chat_off_smoke --samples 10000
& $PY reproduce.py report --run results\deepseek-chat_off_smoke --out reports\deepseek-chat_off_smoke
```

说明：run 支持断点续跑（已成功的 ID 会跳过），中途停止不会重复计费； 更换模型或参数必须换新的 --out
目录；HTTP 400/401/403/404 会立即中止并要求先修配置， 不会静默回退到别的模型或 schema。